

中国科学技术大学



本科毕业论文答辩

随机特征方法求解高维抛物型方程

刘行

中国科学技术大学
少年班学院 信息与计算科学

指导教师: 陈景润教授 2026 年 5 月 27 日

- ① 问题背景: 高维抛物型 PDE 的初值计算.
- ② 方法: PDE-BSDE 转化与随机特征表示.
- ③ 实现: C++/libtorch 中的线性与半线性求解器.
- ④ 实验: 四个 100 维算例, 参数敏感性与 Deep BSDE 对比.
- ⑤ 总结: 方法特点, 局限与后续方向.

第 1 部分

问题背景

目标

对高维半线性抛物型终值问题, 计算给定初始点处的

$$u(0, x_0).$$

统一方程写为

$$\begin{aligned} \partial_t u + \frac{1}{2} \text{Tr}(\sigma \sigma^T \nabla_x^2 u) + \langle \mu, \nabla_x u \rangle \\ + f(t, x, u, \sigma^T \nabla_x u) = 0, \quad u(T, x) = g(x). \end{aligned}$$

困难

- 网格型方法在 d 维空间中规模随维度指数增长.
- 高维情形更适合从样本路径和函数逼近入手.
- 需要同时控制采样误差, 时间离散误差和函数逼近误差.

第 2 部分

方法框架

令正向过程满足

$$X_t = x_0 + \int_0^t \mu(s, X_s) \, ds + \int_0^t \sigma(s, X_s) \, dW_s.$$

若

$$Y_t = u(t, X_t), \quad Z_t = \sigma^T(t, X_t) \nabla_x u(t, X_t),$$

由 Itô 公式得到

$$dY_t = -f(t, X_t, Y_t, Z_t) \, dt + Z_t^T dW_t, \quad Y_T = g(X_T).$$

时间离散后:

$$Y_{k+1} = Y_k - \Delta t f(t_k, X_k, Y_k, Z_k) + \langle Z_k, \Delta W_k \rangle.$$

离散后的未知量

只需要学习初值 Y_0 以及路径点上的梯度变量 Z_k .

对每个时间层和路径点构造固定内层随机特征

$$H_k^{(i)} = \tanh\left(x_k^{(i)} A + t_k b + c\right),$$

其中

$$A_{mh} \sim \mathcal{N}\left(0, \frac{1}{d}\right), \quad b_h, c_h \sim \mathcal{N}(0, 1).$$

用输出层线性组合近似

$$Z_k^{(i)} \approx \alpha H_k^{(i)}, \quad \alpha \in \mathbb{R}^{d \times H}.$$

训练参数

$$\theta = (y_0, \text{vec}(\alpha)).$$

特点

内层参数固定, 优化只发生在输出层. 相比一般神经网络训练, 参数结构更简单.

对线性生成元

$$f(t, x, y, z) = l(t, x)y + \langle m(t, x), z \rangle + n(t, x),$$

本文实验中主要处理 $m \equiv 0$ 的情形. 离散递推为

$$y_{k+1}^{(i)} = (1 - \Delta t l(t_k, x_k^{(i)}))y_k^{(i)} + (\Delta W_k^{(i)})^T \alpha H_k^{(i)} - \Delta t n(t_k, x_k^{(i)}).$$

因而终端值可写成仿射形式

$$y_N^{(i)} = \beta_i y_0 + \langle \Gamma_i, \alpha \rangle + \eta_i.$$

拼接所有路径后求解带岭正则化的最小二乘:

$$\min_{\vartheta} \|\Phi \vartheta - B\|_2^2 + \lambda_r \|R \vartheta\|_2^2, \quad \vartheta = \begin{bmatrix} y_0 \\ \text{vec}(\alpha) \end{bmatrix}.$$

其中正则化只作用在 α 上, 不惩罚 y_0 .

半线性情形中

$$y_{k+1}^{(i)} = y_k^{(i)} - \Delta t f(t_k, x_k^{(i)}, y_k^{(i)}, \alpha H_k^{(i)}) + (\Delta W_k^{(i)})^T \alpha H_k^{(i)}.$$

定义终端残差

$$r_i(\theta) = y_N^{(i)}(\theta) - g(x_N^{(i)}), \quad \min_{\theta} \frac{1}{2} \|r(\theta)\|_2^2.$$

每次 LM 迭代解阻尼线性系统

$$(J^T J + \lambda I) \delta = -J^T r, \quad \theta \leftarrow \theta + \delta.$$

实现要点

HJB-LQ 和 Allen-Cahn 均实现了解析终端残差雅可比, 避免逐样本 autograd 构造大雅可比带来的额外开销.

第 3 部分

程序实现

核心模块

src/equations	方程接口, 采样, f , g , 线性系数与解析雅可比
src/rff	随机特征映射 $\phi(t, x)$
src/solver	线性最小二乘和 LM 求解器
src/config	JSON 参数读取

张量形状

$$X : (S, N, 1, d), \quad H : (S, N, H, 1), \\ \alpha : (d, H), \quad Z : (S, N, 1, d).$$

计算环境

C++/libtorch, float32, CUDA 优先. 标准实验使用 $d = 100$, $N = 20$, $S = 16384$, $H = 50$.

第 4 部分

数值实验

方程	类型	d	T	终端条件或收益
Heat	线性	100	1.0	$g(x) = \exp(-\ x\ ^2/d)$
Black-Scholes	线性	100	1.0	$g(x) = \max(d^{-1} \sum_m x_m - K, 0)$
HJB-LQ	半线性	100	1.0	$g(x) = \log((1 + \ x\ ^2)/2)$
Allen-Cahn	半线性	100	0.3	$g(x) = 1/(2 + 0.4\ x\ ^2)$

误差指标

报告初值相对误差, 训练路径终端 RMSE, 以及独立测试路径终端 RMSE. 训练残差小不必然表示泛化可靠.

方程	y_0	参考值	相对误差	训练 RMSE	测试 RMSE
Black-Scholes	0.048726	0.048813	0.178%	5.2851×10^{-2}	7.4640×10^{-2}
Heat	0.372581	0.371528	0.283%	3.5968×10^{-2}	5.1693×10^{-2}
HJB-LQ	4.590000	4.590162	0.0035%	9.9006×10^{-2}	1.4430×10^{-1}
Allen-Cahn	0.053131	0.052785	0.656%	3.5241×10^{-3}	5.1108×10^{-3}

线性算例

一次岭最小二乘即可得到接近参考值的初值.

半线性算例

LM 在两个典型非线性结构上均能稳定下降并得到有效初值.




图 1: 半线性方程 LM 残差下降




图 2: 样本数对泛化的影响

观察

小样本下可能出现训练残差很小但测试残差和初值误差较大的情况, 因此独立测试路径是必要的诊断指标.




图 3: 运行时间随维度变化

方程	方法	时间 / s	相对误差
HJB-LQ	RFM	3.378	0.0035%
HJB-LQ	Deep BSDE	15.221	0.077%
Allen-Cahn	RFM	3.149	0.656%
Allen-Cahn	Deep BSDE	29.192	0.116%

对比结论

在本文实现和参数下, RFM 用更短时间得到接近参考值的初值. 精度优势依赖具体方程, Allen-Cahn 上 Deep BSDE 更精确但耗时更长.

第 5 部分

总结展望

本文工作

- 将高维抛物型 PDE 转化为 BSDE 路径匹配问题.
- 用固定内层随机特征近似 Z_k , 只训练 y_0 和输出层参数 α .
- 线性问题求解岭最小二乘, 半线性问题求解 LM 非线性最小二乘.
- 在四个 100 维标准算例上取得接近参考值的初值.

后续方向

- 分析采样误差, 时间离散误差和随机特征逼近误差的相对贡献.
- 改进特征尺度选择, 结构化随机特征和特征筛选, 缓解病态最小二乘.
- 对半线性问题引入无矩阵 LM/Gauss-Newton 或分块求解, 降低高维下显存和线性代数开销.

谢谢各位老师!

敬请批评指正

